

Dendê Softhouse: Modelo Preditivo de Dados

Autores: Antônio Gabriel Gomes Falcão do Nascimento
Giovanna Oliveira Araujo
Gustavo Costa Pereira
João Magalhães Mira Neto

Agenda

O objetivo desta apresentação é explicar o modelo preditivo desenvolvido para indicar a probabilidade de cada país vencer a Copa do Mundo de Futebol.

1. Contextualização

Exibição dos processos anteriores e do último do desafio do Dendê Softhouse.

2. Pré-Processamento

Limpeza dos *datasets* fornecidos, visando o objetivo final.

3. Treinamento

Processo de treinamento do modelo utilizando os dados fornecidos.

4. Avaliação dos Modelos:

Exibição dos resultados obtidos a partir do treinamento e teste realizado.

1. Contextualização

Modelo de Recomendação - Programa de Trainee da Dendê Softhouse

Etapas		
1	Análise Exploratória	Modelo de aplicação para análise
2	Pré-Processamento	Limpeza de dados
3	Algoritmos de Regra de Associação	Descoberta de padrões de consumo e afinidade
4	Modelo de Predição	Predição de um resultado através de características

1. Exploração do Dataset

- Objetivo: prever as chances de cada país vencer a competição
- Contém informações de performance de cada seleção



1. Exploração do Dataset



- Possui 250 registros países e 25 atributos quantitativos e qualitativos;

Data columns (total 26 columns):

#	Column	Non-Null Count	Dtype
---	-----	-----	-----
0	team_name	1000 non-null	str
1	country_code	1000 non-null	str
2	confederation	1000 non-null	str
3	fifa_rank	1000 non-null	int64
4	fifa_points	1000 non-null	float64
5	wins_last_10_matches	1000 non-null	int64

1. Exploração do Dataset



O sucesso de uma seleção depende de dimensões complementares:

- Histórico (ranque FIFA);
- Momento (forma recente);
- Técnica (valor de mercado);
- Contexto (clima e logística).

1.1. Escolha das Características



- Colunas preditoras escolhidas:
 - Histórico e Momento;
 - Eficiência em Campo;
 - Talento e Estrutura;
 - Contexto e Clima.

1.1. Escolha das Características




Coluna alvo (target):


```
# A coluna alvo (target) é a coluna winner.  
# Indica o vencedor de cada jogo  
y = df['winner']
```

2. Pré-processamento


Pipeline — test.csv + consistência



2.1 Transformação de Dados Categóricos




```
X_encoded = pd.get_dummies(X, drop_first=True)
colunas_x = X_encoded.columns
```



"Brasil" é a categoria de referência — drop_first remove sua coluna

2.2 Transformação de Dados Categóricos

```
scaler = StandardScaler()  
colunas_x = X_encoded.columns  
X_escalonado = scaler.fit_transform(X_encoded)  
X_final = pd.DataFrame(X_escalonado, columns=colunas_x)
```



3. Treinamento

- O objetivo é capacitar o algoritmo para que identifique os padrões e correlações nos dados.
- Faz o algoritmo generalizar o conhecimento e realizar previsões de partidas futuras



3.2. Treinamento dos Modelos



1 · load_and_split_data()

CSV filepath
validação de existência

X · y
drop target col

train_test_split
80% treino · 20% teste

X_train X_test
y_train y_test

3.2. Configuração de hiperparâmetros

`RandomForestClassifier()` — padrão, sem ajuste

`RandomForestClassifier(n_estimators=200, max_depth=5)` — com tuning

3.2. Treinamento dos Modelos

2 - train_models()



3.3. Predições e Probabilidades

3 - extract_predictions_and_probabilities()

trained_models
+ X_test

predict()
predict_proba()

results dict
predictions · probabilities · classes

3.3. Predições e Probabilidades

4 - Avaliação dos modelos

predictions
+ y_test

accuracy_score
f1_score weighted

print por modelo
Acurácia · F1-Score (4 casas decimais)

3.4. Avaliação dos Modelos

Modelo
Random Forest Default
Random Forest Tuning ★ escolhido
Logistic Regression

O Random Forest Tuning foi selecionado por seu equilíbrio entre performance e generalização — resistente a overfitting por ser um modelo ensemble com hiperparâmetros controlados.

4. Etapas para Resultado Final



4. Resultado Final

★ RANKING DE PROBABILIDADE MÉDIA DE VENCER A COPA ★

	Team	Win_Probability_Percentage
0	France	77.233151
1	Argentina	75.071151
2	England	74.096088
3	Brazil	73.482641
4	Spain	73.345508
5	Croatia	58.235383
6	Italy	57.059753
7	Uruguay	55.415631
8	Colombia	55.021842
9	Netherlands	53.794855

★★★★★★★★★★★★★★★★

VENCEDOR : ★ FRANCE ★

★★★★★★★★★★★★★★★★

Considerações finais



✓ Pontos fortes

- Código modular
- Alinhamento defensivo de colunas
- Média por país reduz ruído
- RF com tuning de hiperparâmetros

△ Melhorias

- Validação cruzada (k-fold)
- Registrar F1, AUC-ROC
- Exibir feature importance
- Calibrar probabilidades (RF)

Referências



- FACELI, Katti et al. Inteligência Artificial: uma abordagem de aprendizado de máquina. 2. ed. Rio de Janeiro: LTC, 2021.
- GÉRON, Aurélien. Mãos à obra: aprendizado de máquina com Scikit-Learn, Keras & TensorFlow. 2. ed. Rio de Janeiro: Alta Books, 2021.
- MCKINNEY, Wes. Python para análise de dados: tratamento de dados com Pandas, NumPy e Jupyter. 3. ed. São Paulo: Novatec, 2023.
- PEDREGOSA, Fabian et al. Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011.